

# Fisherowska dyskryminacja liniowa – zastosowanie dla nowych danych

Marcin Samojluk, Gabriel Rączkowski

December 12, 2024

Fisherowska dyskryminacja liniowa (LDA) jest techniką statystyczną wykorzystywaną w analizie danych. Jej celem jest maksymalizacja rozróżnienia między klasami w zbiorze danych. Wykorzystywana jest głównie w klasyfikacji.

- ▶ LDA znajduje liniową kombinację cech, która najlepiej oddziela klasy.
- ▶ Jest szeroko stosowana w wielu dziedzinach, takich jak biologia, rozpoznawanie twarzy czy analiza tekstów.

Fisherowska dyskryminacja liniowa została zaproponowana przez Ronalda A. Fishera w 1936 roku. Początkowo była stosowana w analizie danych botanicznych, aby rozróżnić różne gatunki roślin na podstawie pomiarów ich cech morfologicznych.

# Motywacja do stosowania LDA

Wyobraźmy sobie, że mamy dwie klasy (np. Klasa A i Klasa B), które chcemy skutecznie od siebie oddzielić. Każda klasa może być opisana przez wiele różnych cech, takich jak:

- ▶ Wzrost, waga,
- ▶ Wiek, poziom wykształcenia,
- ▶ Wyniki testów itp.

**\*\*Problem z jedną cechą:\*\*** Jeśli użyjemy tylko jednej cechy (np. wzrostu), klasy mogą częściowo się nakładać. Nie będziemy w stanie jednoznacznie przypisać danych punktów do jednej z klas.

**Przykład:** Przykład danych w przestrzeni 1D, gdzie klasy nachodzą na siebie.



Fisherowska dyskryminacja liniowa polega na znalezieniu takiej linii (hiperpłaszczyzny), która maksymalizuje stosunek wariancji między klasami do wariancji wewnątrz klas.

Wzór na funkcję celu:

$$J(\mathbf{w}) = \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_W \mathbf{w}}$$

Gdzie:

- ▶  $S_B$  - macierz rozrzutu między klasami,
- ▶  $S_W$  - macierz rozrzutu wewnątrz klas,
- ▶  $\mathbf{w}$  - wektor wag, który określa kierunek linii separującej.

# Wyprowadzenie optymalnego $\mathbf{w}$

Celem jest maksymalizacja funkcji celu:

$$J(\mathbf{w}) = \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_W \mathbf{w}}$$

Aby znaleźć optymalny wektor  $\mathbf{w}$ , liczymy pochodną  $\nabla J(\mathbf{w})$  względem  $\mathbf{w}$ :

$$\nabla J(\mathbf{w}) = 0$$

Rozwijamy krok po kroku w kolejnych slajdach.

# Liczenie pochodnej $\nabla J(\mathbf{w})$

Funkcja celu:

$$J(\mathbf{w}) = \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_W \mathbf{w}}$$

Liczymy pochodną z licznika i mianownika:

$$\nabla (\mathbf{w}^T S_B \mathbf{w}) = 2S_B \mathbf{w}, \quad \nabla (\mathbf{w}^T S_W \mathbf{w}) = 2S_W \mathbf{w}$$

Stosujemy wzór na pochodną ilorazu:

$$\nabla J(\mathbf{w}) = \frac{2S_B \mathbf{w} \cdot (\mathbf{w}^T S_W \mathbf{w}) - 2S_W \mathbf{w} \cdot (\mathbf{w}^T S_B \mathbf{w})}{(\mathbf{w}^T S_W \mathbf{w})^2}$$

Szukamy, kiedy  $\nabla J(\mathbf{w}) = 0$ .

# Warunek stacjonarności

Aby znaleźć maksimum funkcji celu, przyrównujemy pochodną do zera:

$$\nabla J(\mathbf{w}) = 0$$

Co oznacza, że:

$$S_B \mathbf{w} (\mathbf{w}^T S_W \mathbf{w}) = S_W \mathbf{w} (\mathbf{w}^T S_B \mathbf{w})$$

Dzielimy obie strony przez  $(\mathbf{w}^T S_W \mathbf{w})$ :

$$S_B \mathbf{w} = \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_W \mathbf{w}} S_W \mathbf{w}$$

Definiujemy:

$$\lambda = \frac{\mathbf{w}^T S_B \mathbf{w}}{\mathbf{w}^T S_W \mathbf{w}}$$



# Przejdźcie do równania własnego

Otrzymane równanie:

$$S_B \mathbf{w} = \lambda S_W \mathbf{w}$$

Przemnażamy obustronnie przez  $S_W^{-1}$  (zakładamy, że  $S_W$  jest odwracalna):

$$S_W^{-1} S_B \mathbf{w} = \lambda \mathbf{w}$$

Jest to równanie własne, gdzie:

- ▶  $S_W^{-1} S_B$  - macierz,
- ▶  $\lambda$  - wartość własna,
- ▶  $\mathbf{w}$  - wektor własny.

# Interpretacja równania własnego

- ▶ Rozwiązujemy równanie  $S_W^{-1} S_B \mathbf{w} = \lambda \mathbf{w}$ .
- ▶ Wartości własne  $\lambda$  określają zdolność rozróżnienia klas.
- ▶ Optymalny wektor  $\mathbf{w}$  to ten, który odpowiada największemu  $\lambda$ .

Podsumowanie:

$\mathbf{w}$  = wektor własny dla największej  $\lambda$

$J(\mathbf{w})$  maksymalizowane przy  $\lambda_{\max}$

# Rozwiązanie równania

Z równania  $\nabla J(\mathbf{w}) = 0$  wynika, że optymalny  $\mathbf{w}$  musi spełniać:

$$S_W^{-1} S_B \mathbf{w} = \lambda \mathbf{w}$$

Gdzie  $\lambda$  to wartość własna układu. Rozwiązaniem jest:

- ▶  $\mathbf{w}$  - wektor własny macierzy  $S_W^{-1} S_B$ ,
- ▶  $\lambda$  - odpowiadająca wartość własna.

Wybieramy  $\mathbf{w}$ , które odpowiada największej  $\lambda$  (największemu rozróżnieniu między klasami).

# Optymalny wektor $\mathbf{w}$

Podsumowanie:

- ▶ Macierz  $S_W^{-1}S_B$  reprezentuje relację między klasami i zmiennością danych.
- ▶ Wektor  $\mathbf{w}$  odpowiada największej wartości własnej macierzy  $S_W^{-1}S_B$ .
- ▶ Ten wektor  $\mathbf{w}$  maksymalizuje rozróżnienie między klasami w projekcji na linię.

# Wektory Własne w LDA

W metodzie Linear Discriminant Analysis (LDA), kluczowym zadaniem jest znalezienie odpowiednich kierunków w przestrzeni, które najlepiej oddzielają dane. Te kierunki są reprezentowane przez **\*\*wektory własne\*\***.



## Co to są wektory własne?

- ▶ Wektory własne to kierunki, w których dane są najbardziej rozciągnięte, co pomaga je lepiej oddzielić.
- ▶ Wartości własne odpowiadają za "intensywność" tego rozciągania w danym kierunku — większa wartość oznacza silniejszą separację.

## Dlaczego to ważne?

- ▶ Wybieramy te wektory, które mają największe wartości własne, ponieważ pozwalają one uzyskać jak najlepszą separację między klasami.

# Obrazek przedstawiający przekształcenie danych



## Obrazek przedstawia:

- ▶ Jak dane przekształcają się w przestrzeni, gdy używamy wektorów własnych.
- ▶ Wektory własne pokazują kierunki rozciągania danych, co pomaga w lepszej separacji klas.

# Jak działają wektory własne?

W przestrzeni 3D możemy mieć więcej niż jeden wektor własny. W tym przypadku zazwyczaj wybieramy tylko te, które najlepiej rozdzielają klasy.

## Jak to działa w praktyce?

- ▶ W przestrzeni 3D mamy trzy główne wektory, które wskazują kierunki o największej zmienności danych.
- ▶ W LDA, dla dwóch klas, zazwyczaj wystarcza tylko jeden wektor, aby efektywnie oddzielić klasy.
- ▶ Dla większej liczby klas możemy wybrać więcej wektorów, ale w podstawowych przypadkach wystarczy jeden.

## Obrazek przedstawia:

- ▶ Jak dane przekształcają się w przestrzeni, gdy używamy wektorów własnych.
- ▶ Przekształcenie pozwala lepiej rozdzielić klasy.

# Macierz rozrzutu między klasami $S_B$

- ▶ **Macierz rozrzutu między klasami  $S_B$ :** Mierzy, jak różnią się średnie poszczególnych klas w stosunku do globalnej średniej. Celem jest zmaksymalizowanie tej różnicy, aby klasy były jak najbardziej oddzielone.

**Wzór na macierz rozrzutu między klasami:**

$$S_B = \sum_{i=1}^k N_i (\mu_i - \mu)(\mu_i - \mu)^T$$

Gdzie:

- ▶  $N_i$  – liczba próbek w klasie  $i$ ,
- ▶  $\mu_i$  – średnia klasy  $i$ ,
- ▶  $\mu$  – globalna średnia wszystkich próbek.



# Macierz rozrzutu wewnątrz klas $S_W$


- ▶ **Macierz rozrzutu wewnątrz klas  $S_W$ :** Mierzy, jak rozproszone są punkty danych w obrębie każdej klasy. Celem jest minimalizacja tej zmienności, aby dane w obrębie każdej klasy były jak najbardziej jednorodne.

**Wzór na macierz rozrzutu wewnątrz klas:**

$$S_W = \sum_{i=1}^k \sum_{x_j \in C_i} (x_j - \mu_i)(x_j - \mu_i)^T$$

Gdzie:

- ▶  $C_i$  – zbiór punktów należących do klasy  $i$ ,
- ▶  $x_j$  – pojedyncza próbka w klasie  $i$ ,
- ▶  $\mu_i$  – średnia klasy  $i$ .



- ▶ Intuicyjnie rozproszenie wewnątrz klasy sprawdza, jak zwarta jest każda klasa.
- ▶ Rozproszenie między klasami bada, jak daleko od siebie znajdują się różne klasy.

# Rozróżnianie między klasami

Fisherowska dyskryminacja liniowa dąży do znalezienia najlepszego wektora  $\mathbf{w}$ , który maksymalizuje rozróżnienie między klasami.

Celem jest:

- ▶ Projektowanie przestrzeni, w której różnice między klasami są jak najbardziej widoczne.
- ▶ Projekcja danych na wektor  $\mathbf{w}$  pozwala na łatwiejsze przypisanie nowych danych do odpowiednich klas.

# Przykład zastosowania

Założmy, że mamy dane dotyczące roślin i chcemy je sklasyfikować na podstawie cech takich jak długość i szerokość liści.

- ▶ Wybieramy dwie cechy (np. długość i szerokość liści).
- ▶ Fisherowska dyskryminacja liniowa oblicza najlepszą linię separującą te dwie klasy.

Dzięki tej metodzie możemy łatwo oddzielić klasy roślin na podstawie dwóch prostych cech.

# Zastosowanie w rozpoznawaniu twarzy

LDA jest także szeroko stosowane w rozpoznawaniu twarzy, gdzie cechy twarzy (np. odległości między oczami, szerokość nosa) służą do klasyfikacji osób.

- ▶ Twarze osób są reprezentowane jako wektory cech.
- ▶ LDA znajduje projekcję, która maksymalizuje różnice między twarzami różnych osób.

*"Rozpoznawanie twarzy jest jednym z najczęściej stosowanych zastosowań LDA."*

LDA może być również wykorzystywana w analizie tekstów. Na przykład w klasyfikacji e-maili na spam i nie-spam:

- ▶ Cechy: obecność słów, długość e-maila, liczba załączników.
- ▶ LDA identyfikuje najlepsze cechy, które pozwalają na skuteczną klasyfikację.

*„Fisherowska dyskryminacja liniowa jest bardzo efektywna w zadaniach klasyfikacji tekstów.”*

# Przykład z danymi medycznymi

LDA jest także używane w medycynie, np. w klasyfikacji przypadków chorób:

- ▶ Zbieramy dane o pacjentach, np. wyniki badań krwi, ciśnienie.
- ▶ LDA pomaga oddzielić pacjentów zdrowych od chorych na podstawie cech medycznych.

# Wzór na linię separującą

Jeśli mamy dane 2D, najlepsza linia separująca jest opisana przez wzór:

$$\mathbf{w}^T \mathbf{x} + b = 0$$

Gdzie:

- ▶  $\mathbf{w}$  to wektor wag (prostopadły do linii),
- ▶  $\mathbf{x}$  to dane (punkt na wykresie),
- ▶  $b$  to przesunięcie (odległość od początku układu współrzędnych).



Fisherowska dyskryminacja liniowa jest prostą, ale potężną techniką klasyfikacji. Znajduje szerokie zastosowanie w różnych dziedzinach, takich jak medycyna, analiza twarzy czy analiza tekstów. Choć jest to technika liniowa, może być wystarczająca w wielu praktycznych zastosowaniach.

- ▶ Fisher, R. A. (1936). "The Use of Multiple Measurements in Taxonomic Problems". *Annals of Eugenics*.
- ▶ Bishop, C. M. (2006). "Pattern Recognition and Machine Learning". *Springer*.
- ▶ James, G., Witten, D., Hastie, T., & Tibshirani, R. (2013). "An Introduction to Statistical Learning". *Springer*.